

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3074 – Minería de datos

Sección 20

Luis Roberto Furlan Collver



Reporte final - Proyecto final

Integrantes:

Andy Fuentes 22944

Jorge López 221038

Sergio Orellana 221122

Christian Echeverría 221441

Davis Roldán 22672

Guatemala, mayo del 2025

1. Resumen ejecutivo

En este proyecto, como equipo de análisis de datos, enfrentamos el reto de transformar una gran cantidad de información proveniente del e-commerce brasileño Olist en decisiones accionables. Nuestra meta fue clara: identificar patrones que optimicen la logística, anticipen la satisfacción del cliente y comprendan cómo variables como el producto, la región o el método de pago influyen en la experiencia de compra.

Para lograrlo, consolidamos múltiples fuentes de datos, realizamos un análisis exploratorio riguroso y diseñamos un pipeline completo de aprendizaje supervisado. Este pipeline incluyó modelos tradicionales de regresión y clasificación, así como redes neuronales básicas. Además, aplicamos técnicas de validación cruzada para garantizar la confiabilidad de nuestras predicciones.

Entre nuestros principales hallazgos destacan la capacidad de los modelos para anticipar retrasos en la entrega con buen nivel de precisión, la identificación de factores que influyen negativamente en las reseñas, y la importancia crítica de algunas variables como `freight_value` y `payment_value`.


Los resultados no solo permitieron comparar el desempeño de modelos lineales, basados en árboles y neuronales, sino que también arrojaron insights estratégicos que pueden ayudar a Olist a mejorar tanto su eficiencia operativa como la experiencia de sus clientes.

2. Metodología detallada


En esta sección explicamos de forma paso a paso el enfoque que seguimos para transformar los datos, analizarlos, construir modelos predictivos y validar sus resultados. Nuestra metodología combinó técnicas de análisis exploratorio, ingeniería de características y aprendizaje supervisado, aplicadas a modelos de regresión y clasificación.

2.1 Análisis exploratorio de datos (EDA)

Comenzamos evaluando la calidad del dataset. Para ello, creamos un mapa de calor de valores faltantes, lo que nos permitió identificar columnas críticas con valores nulos, principalmente relacionadas con fechas de entrega y aprobación.



También analizamos la correlación entre variables numéricas, como price, freight_value, delivery_days y payment_value, para identificar relaciones significativas para la fase de modelado.



2.2 Preparación de datos

Después del EDA, realizamos las siguientes transformaciones:


- Eliminación de columnas con demasiados valores nulos o sin variabilidad.
- Imputación de valores faltantes usando la mediana.
- Normalización con StandardScaler, útil especialmente para SVM y redes neuronales.
- **Agrupación geográfica:** convertimos dummies de estados (SP, RJ, etc.) en regiones (Sudeste, Sur, etc.) tanto para el vendedor como para el cliente, reduciendo dimensionalidad sin perder semántica.
- **Selección de características:** usamos SelectFromModel con RandomForestRegressor auxiliar para elegir las 30 variables más relevantes.




2.3 Modelos entrenados

Desarrollamos modelos tanto de regresión como de clasificación:

Regresión (predicción de delivery_days):

- Linear Regression
- Support Vector Regressor (SVR)
- Random Forest Regressor






Clasificación (predicción de review_score binarizado):

- Logistic Regression
- Random Forest Classifier
- Linear SVM
- Red Neuronal binaria

Modelo	Accuracy	Precision	Recall	F1	ROC AUC
Regresión logística	0.8009	0.8049	0.9822	0.8847	0.6813
Random Forest	0.8050	0.8081	0.9830	0.8869	0.7068
SVM Lineal	0.7982	0.7994	0.9889	0.8841	N/A




2.4 Validación cruzada

Aplicamos validación cruzada k-fold con $k=5$ para evaluar los modelos de forma robusta. Esto permitió reducir el sesgo de una sola partición train/test y verificar si el modelo es consistentemente bueno.

La red neuronal binaria obtuvo el mejor accuracy promedio (0.8028), seguida por Random Forest (0.8003).

Logistic Regression y SVM obtuvieron valores más bajos y mayor varianza.



2.5 Métricas utilizadas


Utilizamos métricas distintas para cada tipo de tarea:

Regresión:

- RMSE (Root Mean Squared Error)
- R^2 (Coeficiente de determinación)

Clasificación:

- Accuracy, Precision, Recall, F1-score
- ROC-AUC
- Matriz de confusión
- Curva ROC



3. Análisis comparativo de todos los modelos



En esta sección comparamos cuantitativa y cualitativamente el desempeño de los modelos implementados, tanto para la tarea de regresión como para la clasificación binaria. Utilizamos métricas específicas para cada tipo de problema y analizamos su robustez con y sin validación cruzada.

3.1 Modelos de regresión

Objetivo: predecir la variable `delivery_days`.

Entrenamos tres modelos principales:

Modelo	RMSE	R^2
Random Forest	8.069	0.279
Linear Regression	8.439	0.211
SVR (RBF Kernel)	8.449	0.210



Conclusión:

El modelo de Random Forest superó a los demás en ambas métricas. Aunque la mejora en RMSE parece moderada, en términos de explicación de la varianza (R^2), la diferencia fue significativa. Esto sugiere que captura relaciones no lineales relevantes para predecir el tiempo de entrega.

3.2 Comparación con y sin validación cruzada

Implementamos validación cruzada de 5 particiones ($k=5$) para todos los modelos de clasificación. Observamos lo siguiente:

Modelo	Accuracy Promedio (CV)	Desviación
Red Neuronal	0.8028	± 0.0015
Random Forest	0.8003	± 0.0019
Logistic Regression	0.6899	± 0.0013
Linear SVM	0.6984	± 0.0012

Conclusión:

Los resultados validan que tanto el Random Forest como la red neuronal binaria mantienen su buen desempeño de forma consistente. Esto indica que no están sobreajustados a una sola partición. En contraste, Logistic Regression y SVM mostraron menor precisión promedio y mayor sensibilidad a la partición.

3.3 Red neuronal vs modelos clásicos (clasificación)

Objetivo: predecir si una reseña será positiva ($\text{review_score} \geq 4$) o negativa/neutra.

Modelo	Accuracy	Precision	Recall	F1-score	ROC-AUC
Red Neuronal	0.8028	0.806	0.979	0.884	0.70
Random Forest	0.805	0.808	0.982	0.887	0.70
Logistic Regression	0.800	0.805	0.982	0.884	0.68

Conclusión:

Tanto la red neuronal como Random Forest alcanzan un ROC-AUC de 0.70, indicando un buen desempeño en separación de clases. Sin embargo, la red neuronal mostró una ventaja ligera en precisión promedio con menor varianza, lo cual la posiciona como la más robusta para esta tarea.

3.4 Comparación con baseline: impacto práctico del modelo de regresión

Para evaluar la utilidad práctica del modelo de regresión, lo comparamos contra un enfoque naïve que consiste en tomar como predicción la fecha estimada por Olist (`'order_estimated_delivery_date'`), sin aplicar ningún modelo.

Resultados:

Método	MAE (días)	Cobertura ± 2 días
Baseline (naïve)	6.36	19%
Random Forest	5.45	28%

Interpretación:

- El modelo Random Forest reduce el MAE en 0,91 días ($-14,3\%$), acercando las predicciones a la fecha real de entrega.
- La cobertura dentro de ± 2 días sube del $19,0\%$ al $28,0\%$, lo que representa una mejora relativa del 47% .
- La curva CDF de error muestra que, para cualquier nivel de tolerancia, el modelo predice mejor que el baseline en todos los rangos.


Este resultado valida el valor operativo del modelo para generar fechas de entrega más confiables y realistas.

4. Insights de negocio y recomendaciones

Tras realizar un análisis exhaustivo de los datos históricos de Olist, aplicar modelos de regresión y clasificación, y evaluar su rendimiento con validación cruzada, extraemos los siguientes aprendizajes clave y recomendaciones accionables para el negocio.

4.1 Variables más influyentes

A través del análisis de importancia de variables en el modelo de Random Forest, identificamos los principales factores que afectan tanto el tiempo de entrega como la satisfacción del cliente (review_score).



- **freight_value:** el costo del envío es una de las variables más determinantes. Envíos más costosos se relacionan con mayores tiempos de entrega, lo que puede influir negativamente en la percepción del cliente.
- **payment_value:** montos altos de pago suelen asociarse con productos de mayor tamaño o valor, lo cual puede afectar tanto el envío como la expectativa del cliente.
- **delivery_days:** como es esperable, los días que tarda el pedido en llegar al cliente impactan directamente en la satisfacción. Cuanto mayor el retraso respecto a la fecha estimada, mayor la probabilidad de obtener una reseña negativa.
- **product_weight_g** y dimensiones del producto también resultaron relevantes, lo que tiene sentido ya que afectan los tiempos de manipulación y entrega.

4.2 Recomendaciones estratégicas

Basándonos en los resultados, proponemos a Olist las siguientes acciones:

Optimización logística por producto y región

- Ajustar la promesa de entrega según la categoría del producto y la región del cliente. Los productos más pesados o con mayores valores de envío podrían requerir un buffer mayor.
- Implementar modelos predictivos como el desarrollado para estimar tiempo de entrega personalizado por orden.

Alertas de riesgo en reseñas

- Usar el modelo de clasificación para predecir, en tiempo real, la probabilidad de que un pedido reciba una mala reseña. Esto permitiría activar alertas tempranas y ofrecer asistencia proactiva.

Segmentación y personalización

- Identificar segmentos sensibles al tiempo de entrega (ej. tecnología, electrodomésticos) y brindarles atención diferenciada.
- Potenciar las regiones donde los envíos cumplen consistentemente con los tiempos estimados para fortalecer la reputación de servicio.

Mejora de reportes internos

- Incorporar dashboards con métricas como accuracy y recall del modelo de reseñas, y RMSE de entrega para monitorear la efectividad de los modelos con nuevos datos.

Conclusión final

A lo largo de este proyecto podemos concluir que:

- Limpieza, ingeniería de variables y modelado nos permitieron convertir datos crudos en decisiones concretas.
- Comprobamos que la satisfacción del cliente puede predecirse con buena precisión, y que existen patrones logísticos que impactan directamente en la percepción del servicio.
- Recomendamos a Olist integrar estos modelos en su operación diaria y continuar alimentándolos con nuevos datos para sostener la mejora continua.