

**MINERÍA
DE DATOS**

SEMANA 2 PROY 3

Andy Fuentes 22944

Jorge Lopez 221038

Davis Roldan 22672

Sergio Orellana 221122

Christian Echeverria



INTRODUCCION

En esta semana se implementaron modelos de regresión utilizando el dataset de e-commerce brasileño de Olist, con el objetivo de analizar su desempeño predictivo y optimizar variables clave del negocio.




OBJETIVO

Aplicar y comparar diferentes modelos de regresión, ajustar sus parámetros, evaluar métricas de rendimiento y seleccionar el mejor modelo para la predicción de variables estratégicas.




COMPARACIÓN DE MODELOS DE REGRESIÓN

Random Forest obtuvo el mejor desempeño en términos de error (RMSE) y capacidad explicativa (R^2).




VARIABLES MÁS RELEVANTES



Freight_value, review_score y payment_value son las variables que más impactan la predicción.

ANÁLISIS DE RESIDUOS

Los residuos presentan distribución simétrica y media cercana a cero, indicando un buen ajuste del modelo.



EVALUACIÓN DE MODELOS

- Random Forest
- Linear Regression
- SVR



Modelo	RMSE	R ²
Random Forest	8.069	0.279
Linear Regression	8.439	0.211
SVR	8.449	0.210

ANÁLISIS DE IMPORTANCIA DE VARIABLES



- Top 15 variables importantes extraídas del Random Forest.
- Variable más importante: ``freight_value``.

ANÁLISIS DE LOS RESIDUALES (CONCLUSIÓN)



Distribución de errores centrada cerca de 0.
– Existencia de outliers detectada.

Conclusión: Buen ajuste general, aunque con oportunidades de mejora.

CONCLUSIONES GENERALES



- El pipeline es robusto y profesional.
- Random Forest fue el mejor modelo.
- Variables logísticas como ``freight_value`` son clave.
- La validación con Train/Test asegura métricas realistas.
- RandomizedSearchCV optimizó de forma eficiente.
- El análisis de residuos confirma la ausencia de sesgos graves.



GRACIAS!

See You Next

