

**MINERÍA
DE DATOS**

SEMANA 2 PROY 3

Andy Fuentes 22944

Jorge Lopez 221038

Davis Roldan 22672

Sergio Orellana 221122

Christian Echeverria



INTRODUCCION

En esta semana se implementaron modelos de regresión utilizando el dataset de e-commerce brasileño de Olist, con el objetivo de analizar su desempeño predictivo y optimizar variables clave del negocio.




OBJETIVO

Aplicar y comparar diferentes modelos de regresión, ajustar sus parámetros, evaluar métricas de rendimiento y seleccionar el mejor modelo para la predicción de variables estratégicas.




COMPARACIÓN DE MODELOS DE REGRESIÓN

Random Forest obtuvo el mejor desempeño en términos de error (RMSE) y capacidad explicativa (R^2).




VARIABLES MÁS RELEVANTES



Freight_value, review_score y payment_value son las variables que más impactan la predicción.

ANÁLISIS DE RESIDUOS

Los residuos presentan distribución simétrica y media cercana a cero, indicando un buen ajuste del modelo.



EVALUACIÓN DE MODELOS

- Random Forest
- Linear Regression
- SVR



Modelo	RMSE	R ²
Random Forest	8.069	0.279
Linear Regression	8.439	0.211
SVR	8.449	0.210

ANÁLISIS DE IMPORTANCIA DE VARIABLES



- Top 15 variables importantes extraídas del Random Forest.
- Variable más importante: ``freight_value``.

ANÁLISIS DE LOS RESIDUALES (CONCLUSIÓN)



Distribución de errores centrada cerca de 0.
– Existencia de outliers detectada.

Conclusión: Buen ajuste general, aunque con oportunidades de mejora.

CONCLUSIONES GENERALES




- El pipeline es robusto y profesional.
- Random Forest fue el mejor modelo.
- Variables logísticas como ``freight_value`` son clave.
- La validación con Train/Test asegura métricas realistas.
- RandomizedSearchCV optimizó de forma eficiente.
- El análisis de residuos confirma la ausencia de sesgos graves.




Semana 3

Proyecto 3

Mineria de Datos







INTRODUCCIÓN

Comparación entre Regresión Logística, Random Forest y SVM Lineal para predecir la satisfacción del cliente con base en su evaluación.


DESEMPEÑO GENERAL DE LOS MODELOS



Random Forest lidera en accuracy, precision y f1. SVM Lineal tiene el recall más alto, útil si queremos reducir falsos negativos.




COMPARACIÓN DE MATRICES DE CONFUSIÓN




SVM LINEAL ACIERTA MÁS POSITIVOS (RECALL ALTO) PERO COMETE MÁS FALSOS POSITIVOS. RANDOM FOREST MANTIENE BUEN EQUILIBRIO.




CURVAS ROC




Forest muestra la mejor AUC (0.71), indicando mejor separación entre clases positivas y negativas.






TOP 10 CARACTERÍSTICAS MÁS IMPORTANTES POR MODELO

delivery_days,
payment_value y
price son variables
clave en los tres
modelos. RF y LR
dan mayor peso a
estas.



CONCLUSIONES

- ♦ Random Forest fue el modelo con mejor rendimiento general en todas las métricas clave, destacando especialmente en ROC AUC, lo que indica una alta capacidad de discriminación.
- ♦ SVM Lineal mostró el mayor recall, siendo ideal para contextos donde los falsos negativos representan un riesgo importante.
- ♦ Regresión Logística ofreció resultados consistentes y es una excelente opción cuando la interpretabilidad del modelo es prioritaria.
- ♦ Comparar múltiples modelos permitió una evaluación más robusta y completa del problema.



RECOMENDACIONES

- ♦ Adoptar Random Forest como modelo base para producción por su rendimiento equilibrado y robustez.
- ♦ En aplicaciones donde el costo de los falsos negativos sea alto (e.g., retención de clientes), considerar el uso de SVM Lineal.
- ♦ Utilizar Regresión Logística como modelo complementario cuando se requiera mayor claridad en la explicación de decisiones.





Gracias